

회귀 · 군집 모델 전략

비즈니스 · 부트캠프 발표

거래건수 예측(회귀) → 활동성 갭 → 고객 세그먼트(군집)

조기경보와 캠페인 우선순위를 위한 데이터 기반 의사결정

0.86

기본 RF Val R²

0.73

최종 갭 AUC

43%

하위20% 포착

36%

우선케어 이탈

회귀 진행 방향

기준선 확보 → 금액 의존 발견 → 튜닝으로 상승 → 목적 지표로 최종

01

기본모델

RF 0.86

원본 피쳐 기준선

02

특징공학

+0.0008

금액 의존 발견

03

하이퍼·고도화

+0.02

Voting 0.8666

04

비교·최종

AUC 0.73

금액 제외 B

이 단계로 얻은 것


- 예상 거래건수 예측 능력
- 실제 예상 = 활동성 갭 정의
- 조기경보용 평가 지표(갭 AUC)

결과

- 최종: 금액 제외 Voting B
- 갭 AUC 0.73 · 포착 43%
- OOF 갭 → 군집 입력 연결

1. 기본모델 — LR / RF / XGB

원본 피쳐 · Val R^2 · 6:2:2 · notebooks/04 baseline_results




이 모델을 사용해 얻은 것

- LR/RF/XGB로 '원본만으로 어디까지 가나' 기준선 확보
- Val R^2 로 공정 비교(6:2:2)

결과

- LR 0.6731 — 선형 한계
- RF 0.8639 ★ — 최고
- XGB 0.8388 — FE 튜닝 축
- 비선형 트리가 기본 후보
- 참고선 0.80 이상 = 실무 수준

2. 특징공학 — 파생 4종과 금액 의존



이 단계를 사용해 얻은 것

- 파생 4종으로 입력 개선 시도
- 변수 중요도로 '무엇에 의존하는지' 확인

결과

- R² 상승은 +0.0008로 미미
- 금액이 예측을 압도
- → 조기경보에 금액 함정 가능성 발견
- 결정: A/B로 목적 검증

파생 4종


리볼빙_한도_비율 · 상품당_관계밀도 · 문의_대비_보유기간 · 연령대

핵심: FE의 가치는 '점수 상승'이 아니라 '금액 의존'을 발견한 것

3. 하이퍼·고도화 — 튜닝 · Voting

베이스 0.8388 → FE 0.8396 →

최적화 결과: 앙상블까지 가도 Validation R² 향상폭은 0.03 미만 — 성능 대부분은 이미 피처에서 나온다



이 단계를 사용해 얻은 것

- 하이퍼파라미터 튜닝으로 성능 상승
- Voting으로 모델 결합·안정화
- OOF로 전체고객 겹 산출 기반



결과

- Val R² 최고 Voting 0.8666
- Voting ★ 채택 / Stacking 탈락
- (Stacking nested OOF 예측 붕괴)

4. 비교·최종 — 선택 이유

높은 $R^2(A)$ 를 버리고 금액 제외 B를 채택 · 조기경보 목적

구분	Test R^2	MAE	갭 AUC	하위20% 포착
A 금액포함	0.858	6.95	0.629	30.9%
B 금액제외 ★	0.304	15.22	0.732	43.7%



이 선택으로 얻은 것 / 결과

- 목적=조기경보로 재정의
- A의 높은 R^2 는 금액 의존
- B가 갭 AUC·포착 우위

결과

- 갭 AUC 0.73 · 포착 43%
- 갭 ↓ → 이탈률 ↑ 확인
- OOF 갭 → 군집 입력

군집 진행 방향

행동 기준선 → 갭·관점 FE → 알고리즘·k 탐색 → 3단계 케어 최종

01

기본모델

Sil 0.22

행동 KMeans

02

특징공학

갭 투입

관점 4종

03

하이퍼·탐색

GMM/k

Sil+운영해석

04

비교·최종

k=3

우선케어 36%

이 단계로 얻은 것



- 고객을 행동·갭 기준으로 묶기
- 운영용 3단 라벨 설계
- 회귀 OOF 갭을 군집 입력으로

결과

- 최종 GMM spherical k=3
- 우선케어 이탈률 36%
- 캠페인 우선순위 제공

1. 기본모델 — 행동 KMeans

거래건수·이용률·리볼빙·문의·관계수 · $k=2\sim 8$ 후 $k=3$ · Silhouette 0.22



얻은 것 / 결과

- 행동 기준선
군집 확보

결과

- Sil 0.22
- 분리 약함
- 해석은 가능
하나 케어단
계로는 부족
- → 갭 FE로
강화 결정

2. 특징공학 — 관점·갭 피쳐

행동/확장/신용/갭 관점 세트 · 갭 재설계 후 Silhouette 목표 0.4 달성

행동 기본

거래·이용률·리볼빙·문의·관계

기준선

행동 확장

금액·변화량·연령 등

EDA 확장

신용 여력


한도·OTB·이용률·리볼빙

고한도 저활용

활동성 갭

실제 + 회귀 OOF 갭

조기 위험군



이 단계를 사용해 얻은 것 / 결과

- 회귀 Voting B의 OOF 갭을 군집 입력으로 넣어 '예상 대비 감소' 축을 만들 (Target 미사용·누수 방지)
- 결과: k=3에서 Silhouette 0.405로 목표 0.4 달성 → 운영 라벨링(우선/일반/우량) 가능

3. 하이퍼·탐색 — 알고리즘 · k · 공분산

Silhouette만으로 고르지 않고, 운영 3단이 나오는 조합을 선택

KMeans k=2

0.5245

분리 높음 · 2단계만

KMeans k=3

0.4473

3단계 해석 가능

GMM sph k=2

0.5295

수학 분리 최고 후보

GMM sph k=3 ★



0.4759

우선 / 일반 / 우량

이 탐색으로 얻은 것 / 결과

- 얻은 것: 알고리즘·k·공분산 후보 비교표 · 비즈니스 3단 요구사항과의 정합 기준
- 결과: Silhouette 최고(k=2)가 아니라 GMM spherical k=3 채택 — 우선케어 운영이 가능해서

4. 비교·최종 — 활동성 갭 프로파일



결과 수치

- 우선케어 3,618명 · 갭 -19.5 · 이탈 36%
- 일반 5,262명 · 갭 +6.4 · 이탈 6%
- 우량 1,247명 · 갭 +29.5 · 이탈 1%

이 모델로 얻은 것 / 결과

- 얻은 것: '누구에게 먼저 캠페인할지' 우선순위 라벨 (단순 유형 분류를 넘어)
- 결과: 갭이 낮을수록 이탈 위험이 큼 → 우선케어에 리텐션 자원 집중